analyse multivarié - jour 1

m2iformation.fr

Sommaire

1. Introduction à l'analyse multivarié
2. Analyse des corrélations
3. **A**nalyse en **C**omposante **P**rincipale (ACP)

Utopios® Tous droits réservés

Introduction à l'analyse multivarié

Utopios® Tous droits réservés

Qu'est ce que l'analyse multivariée ?

L'**analyse multivariée** regroupe les techniques statistiques permettant d'analyser **simultanément plusieurs variables** dans un jeu de données. Cela permet de :

- **Réduire la dimensionnalité** : Simplifier des données complexes.
- **Identifier des patterns** : Découvrir des structures cachées.
- **Comprendre les rélations** : voir comment les variables interagissent.
- **Préparer les données**: pour le machine learning.

Utopios® Tous droits réservés

Cas d'usage concrets

- **Marketing** : Segmentation client basée sur plusieurs comportements.
- **Finance** : analyse de portefeuilles d'investissement.
- **Santé** : identification de facteurs de risque multiples.
- **E-commerce** : recommandations produits.

Utopios® Tous droits réservés

Analyse des corrélations

Utopios® Tous droits réservés

Comprendre la corrélation

- La **corrélation** mesure la force et la direction de la relation linéaire entre deux variables.
- **Le coefficient de corrélation de Pearson (r)**
  - **Intervalle** : -1 à +1
  - **r = +1** : Corrélation positive parfaite (quand X augmente, Y augmente)
  - **r = 0** : pas de corrélation linéaire
  - **r = -1** : Corrélation négative parfaite (quand X augmente, Y diminue)

Utopios® Tous droits réservés

Interprétation pratique

- **|r|** < 0.3 : Corrélation faible
- 0.3 <= **|r|** < 0.7 : Corrélation modérée
- **|r|** >= 0.7 : Corrélation forte

/!\ **Attention**: Corrélation n'est pas causalité !
Exemple : On observe que les personnes qui portent un briquet sur elles ont plus de cancers du poumon. Le briquet cause-t-il le cancer ? Non, c'est le tabagisme qui explique à la fois le port du briquet ET le cancer.

Utopios® Tous droits réservés

Demo 01

Utopios® Tous droits réservés

Analyse en composantes principales

Utopios® Tous droits réservés

Qu'est-ce que l'ACP ?

- L'**ACP** (ou PCA en anglais) est une technique de **réduction de dimensionnalité**:
  - **Objectif**: Transformer des variables corrélées en nouvelles variables non-corrélées (les composantes principales)
  - **Principe**: Trouver les directions de plus grande variance dans les données.
  - **Résultat** : Réduire 10 variables en 2-3 composantes qui capturent 80-90% de l'information.

Utopios® Tous droits réservés

Pourquoi utiliser l'ACP ?

- **Simplifier** : Passer de 20 variables à 3 composantes.
- **Visualiser** : Projeter des données multi-dimensionnelles en 2D/3D.
- **Détecter** : Identifier des groupes ou patterns cachés.
- **Préparer** : Améliorer les performances des modèles de ML.
- **Comprendre** : Voir quelles variables contribuent le plus.

Utopios® Tous droits réservés

Cas d'usage

- **Marketing** : Segmentation clients à partir de multiples comportements
- **Finance** : Analyse de portefeuilles avec de nombreux actifs
- **Biologie** : Analyse de données génomiques (milliers de gènes)
- **Image** : Compression et reconnaissance faciale

Utopios® Tous droits réservés

Préparation des données pour l'ACP

- **CRUCIAL** : L'ACP est sensible aux échelles, il faut **normaliser** les données.
- Pourquoi normaliser ?
  - **Revenu** : entre 20 000€ et 120 000€
  - **Score satisfaction** : entre 1 et 5

Sans normalisation, l'ACP sera dominée par la variable avec les plus grandes valeurs (le revenu), même si la satisfaction est tout aussi importante.

Utopios® Tous droits réservés

UTOPIOS®
TRANSFORMATION DIGITALE INTELLIGENTE

Demo 02

Utopios® Tous droits réservés

Quand utiliser quoi ?

Objectif	Méthode	Cas d'usage
Comprendre relations entre 2 variables	Corrélation	"Le prix affecte-t-il les ventes ?"
Vue d'ensemble des relations	Matrice de corrélation + Heatmap	"Quelles variables sont liées ?"
Réduire le nombre de variables	ACP	"Simplifier 20 variables en 3 composantes"
Visualiser des données complexes	ACP + projection 2D	"Voir des groupes de clients"
Préparer pour le ML	ACP	"Réduire dimensions avant clustering"

Utopios® Tous droits réservés

Erreurs fréquentes à éviter

- **Ne pas** confondre corrélation et causalité
  - "X et Y sont corrélés" ≠ "X cause Y"
- **Ne pas** oublier de normaliser avant l'ACP
  - Toujours utiliser StandardScaler()
- **Ne pas** garder trop de composantes
  - Objectif : 80-90% de variance avec le minimum de composantes

Utopios® Tous droits réservés

Erreurs fréquentes à éviter

- **Ne pas** sur-interpréter les résultats
  - Les composantes principales sont des combinaisons mathématiques, pas toujours des concepts business clairs
- **Ne pas** ignorer le contexte métier
  - Les chiffres doivent avoir du sens dans votre domaine

Utopios® Tous droits réservés

UTOPIOS®
TRANSFORMATION DIGITALE INTELLIGENTE

Merci pour votre attention

Des questions ?

Utopios® Tous droits réservés

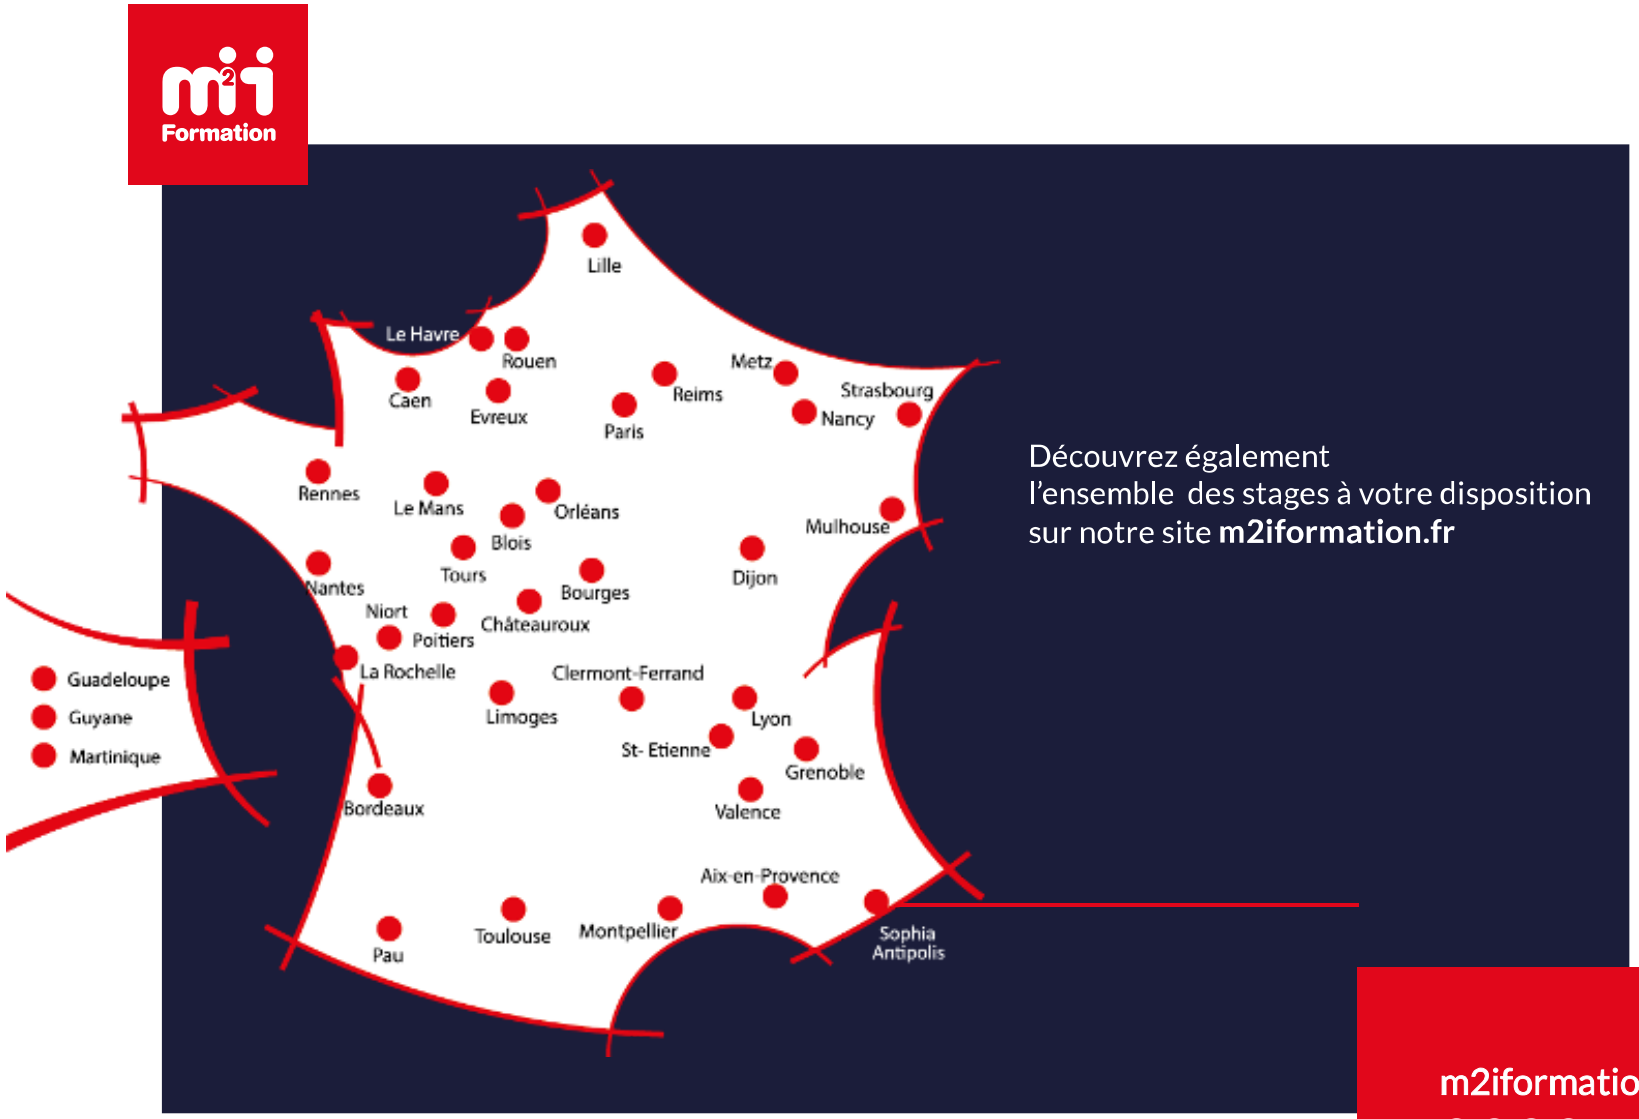

Découvrez également
l'ensemble des stages à votre disposition
sur notre site **m2information.fr**

m2iformation.fr